

HW 2

/ /

① Encontre a função geradora de momentos para

- Ⓐ A distribuição Normal;
- Ⓑ A distribuição Gamma;
- Ⓒ A distribuição de Poisson.

Ⓐ Seja $X \sim N(\mu, \sigma^2)$

$$M_X(t) = E[e^{tx}] = \int e^{tx} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}(x-\mu)^2/\sigma^2} dx$$

Seja $z = \frac{x-\mu}{\sigma}$, ou seja $x = z\sigma + \mu$. Daí

$$\begin{aligned} M_X(t) &= e^{\mu t} \int e^{z\sigma t} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2}z^2} \left| \frac{dx}{dz} \right| dz \\ &= e^{\mu t} \int e^{z\sigma t} \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}z^2} dz \\ &= e^{\mu t} e^{\frac{1}{2}\sigma^2 t^2} \end{aligned}$$

Ⓑ Sendo $X \sim \text{Gamma}(\alpha, \beta)$

$$M_X(t) = E[e^{tx}] = \int_0^{\infty} e^{tx} f_X(x) dx$$

Quebrando em cores;

• $t < \beta$

$$M_X(t) = \frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^{\infty} x^{\alpha-1} e^{-(\beta-t)x} dx$$

$$(u = x(\beta-t)) \rightarrow \frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^{\infty} \left(\frac{u}{\beta-t} \right)^{\alpha-1} e^{-u} \frac{du}{\beta-t}$$

$$= \frac{\beta}{\Gamma(\alpha)(\beta-t)^\alpha} \int_0^{\infty} u^{\alpha-1} e^{-u} du$$

$$= \frac{\beta^\alpha \Gamma(\alpha)}{\Gamma(\alpha)(\beta-t)^\alpha}$$

$$= \left(\frac{\beta}{\beta-t}\right)^\alpha = \left(1 - \frac{t}{\beta}\right)^{-\alpha}$$

• $t = \beta$, nossa integral fica

$$\frac{\beta^\alpha}{\Gamma(\alpha)} \int_0^\infty x^{\alpha-1} dx = \frac{\beta^\alpha}{\alpha \Gamma(\alpha)} [x]_0^\infty$$

$$= 0 + \frac{\beta^\alpha}{\alpha \Gamma(\alpha)} \lim_{x \rightarrow \infty} x^\alpha \rightarrow \infty$$

• $t > \beta$, nesse caso $-(\beta-t)$ é positiva, como consequência $x^{\alpha-1} < e^{(\beta-t)x}$ para x suficientemente grande. Assim a integral também converge para infinito.

$$M_X(t) = \begin{cases} \left(1 - \frac{t}{\beta}\right)^{-\alpha} & t < \beta \\ \text{"não existe"} & t \geq \beta \end{cases}$$

© Sendo $X \sim \text{Poisson}(\lambda)$

$$M_X(t) = E[e^{tx}] = \sum_{k=0}^{\infty} e^{tk} \frac{1}{k!} \lambda^k e^{-\lambda}$$

$$= e^{-\lambda} \sum_{k=0}^{\infty} \frac{(e^t \lambda)^k}{k!}$$

$$= e^{-\lambda} e^{e^t \lambda} = e^{\lambda(e^t - 1)}$$

(2) Suponha que temos uma ~~var~~ v.a. positiva $X \geq 0$, e suponha também que a mgf $M_X(t) \forall t \geq 0$. Mostre que

$$\inf_{k=0,1,2,\dots} \frac{E[X^k]}{u^k} \leq \inf_{t \geq 0} \frac{E[e^{tX}]}{e^{tu}}$$

Isso implica que o melhor limite de cauda de momento nunca é pior que o limite de Chernoff. Geralmente usamos o método de Chernoff, por que é tipicamente muito mais fácil encontrar o melhor t do que encontrar o melhor k .

Seja $t > 0$, então usando expansão em séries de potências e pelo teorema da convergência monotônica, temos $E[e^{tX}] = E[\sum \frac{t^k X^k}{k!}] = \sum \frac{t^k E[X^k]}{k!}$. Daí

$$\begin{aligned} \frac{E[e^{tX}]}{e^{tu}} &= \frac{\sum_k \frac{t^k E[X^k]}{k!}}{\sum_k \frac{t^k u^k}{k!}} = \lim_K \frac{1 + tEX + \dots + \frac{t^K EX^K}{K!}}{1 + tu + \dots + \frac{t^K u^K}{K!}} \\ &\stackrel{(1)}{\geq} \min_{j \leq K} \frac{t^j EX^j}{j! t^j u^j} = \min_{j \leq K} \frac{E[X^j]}{u^j} \end{aligned}$$

(1) segue pela desigualdade de Cauchy-Schwarz que se $a_1, \dots, a_n, b_1, \dots, b_n$ são não negativos temos que

$$\frac{a_1 + \dots + a_n}{b_1 + \dots + b_n} \geq \min_{K \leq n} \frac{a_K}{b_K}$$

Daí, temos que $\forall t > 0$

$$\frac{E[e^{tX}]}{e^{tu}} \geq \inf_K \frac{E[X^K]}{u^K}$$

1 / 1
③ Construa uma v.a. X para a qual a desigualdade de Chebyshev seja rigorosa, ou seja, $P(|X - \mu| > t) = \sigma^2/t^2$.

Seja uma v.a. X tal que

$$f_X(x) = \begin{cases} \mu + t, & \text{com prob. } \frac{\sigma^2}{2t^2} \\ \mu - t, & \text{com prob. } \frac{\sigma^2}{2t^2} \\ \mu, & \text{" " } 1 - \frac{\sigma^2}{t^2} \end{cases}$$

$$\bullet EX = (\mu + t)\frac{\sigma^2}{2t^2} + (\mu - t)\frac{\sigma^2}{2t^2} + \mu\left(1 - \frac{\sigma^2}{t^2}\right) = \mu$$

$$\bullet EX^2 = (\mu + t)^2\frac{\sigma^2}{2t^2} + (\mu - t)^2\frac{\sigma^2}{2t^2} + \mu^2\left(1 - \frac{\sigma^2}{t^2}\right) =$$

$$\text{Var}(X) = EX^2 - \mu^2 = \sigma^2.$$

Daí, por construção temos que

$$P(|X - \mu| \geq t) = \frac{\sigma^2}{t^2}.$$

④ Prove que

$$\text{Var } Y = E[\text{Var}[Y|X]] + \text{Var}[E[Y|X]]$$

$$\text{Var } Y = E[Y^2] - (EY)^2$$

$$= E[E[Y^2|X]] - (E[E[Y|X]])^2$$

$$= E[\text{Var}(Y|X)] + E[(E[Y|X])^2] - (E[E[Y|X]])^2$$

Usando que $\text{Var}(E[Y|X]) = E[E[Y|X]]^2 - (E[E[Y|X]])^2$. De-
termina-se que

$$\text{Var } Y = E[\text{Var}(Y|X)] + \text{Var}(E[Y|X])$$

5) Suponha que $X \geq 0$ é uma v.a. contínua e que X tem média μ . Mostre que

$$\mu = \int_0^{\infty} P(X > x) dx.$$

Sabemos que

$$\mu = E[X] = \int_0^{\infty} x f_x(x) dx$$

Usando integração por partes $u = x$ e $dv = f_x(x) dx$, daí $du = dx$ e $v = F_x(x)$

$$\mu = [x \cdot F_x(x)]_0^{\infty} - \int_0^{\infty} F_x(x) dx$$

$$= 1 - \int_0^{\infty} F_x(x) dx$$

$$= \int_0^{\infty} 1 - F_x(x) dx = \int_0^{\infty} P(X > x) dx.$$