

HW 5

- ① One o Uma observação de uma variável aleatória discrete com pmf $f(x|\theta)$, onde $\theta \in \{1, 2, 3\}$. Encontre o MLE de θ

x	$f(x 1)$	$f(x 2)$	$f(x 3)$
0	$\frac{1}{3}$	$\frac{1}{4}$	0
1	$\frac{1}{3}$	$\frac{1}{4}$	0
2	0	$\frac{1}{4}$	$\frac{1}{4}$
3	$\frac{1}{6}$	$\frac{1}{4}$	$\frac{1}{2}$
4	$\frac{1}{6}$	0	$\frac{1}{4}$

Para cada valor de x , o MLE de $\hat{\theta}$ é o valor de θ que maximiza $f(x|\theta)$. Os valores são

x	0	1	2	3	4
$\hat{\theta}$	1	1	$\frac{2}{3}$	3	3

Em $x=2$, $f(x|2)=f(x|3)=\frac{1}{4}$ (neste caso $\hat{\theta}=2$ e $\hat{\theta}=3$ são MLEs).

② Pode-se amostrar aleatoriamente X_1, \dots, X_n para uma população com pd. f. $f(x|\theta)$, mostrando que maximizando a função de verossimilhança, $L(\theta|x)$, é equivalente a maximizar $\log L(\theta|x)$.

A função log é estritamente crescente, logo

$$L(\theta|x) < L(\hat{\theta}|x) \Leftrightarrow \log L(\theta|x) < \log L(\hat{\theta}|x)$$

Então o $\hat{\theta}$ que maximiza $L(\theta|x)$ também maximiza $\log L(\theta|x)$.

③ Considere estimar o parâmetro da binomial K . De forma gree, seja X_1, \dots, X_n uma amostra para uma binomial (K, p) , onde p é conhecido e K não. A verossimilhança é

$$L(K|x, p) = \prod_{i=1}^n \binom{K}{x_i} p^{x_i} (1-p)^{K-x_i}.$$

Se $K < \max x_i$, então $L(K|x, p) = 0$. Ent. Por isso vamos assumir $K \geq \max x_i$ que significa que $L(K|x, p) / L(K-1|x, p) \geq 1$ e $L(K+1|x, p) / L(K|x, p) \leq 1$. A razão da verossimilhança é

$$\frac{L(K|x, p)}{L(K-1|x, p)} = \frac{(K(1-p))^n}{\prod_{i=1}^n (K-x_i)}$$

Portanto a condição para o máximo é

$$(K(1-p))^n \geq \prod_{i=1}^n (K-x_i) \text{ e } ((K+1)(1-p))^n \leq \prod_{i=1}^n (K+1-x_i)$$

Dividindo por K^n e escrevendo $Z = 1/K$, queremos mostrar

$$(1-p)^n = \prod_{i=1}^n (1-x_i Z), \text{ para os } Z \leq 1/\max x_i.$$

O lado direito é estritamente decrescente em Z para Z neste intervalo com valor 1 para $Z=0$ e 0 para $Z=1/\max x_i$. Então há um única Z que resolve esta equação. O valor de $1/Z$ pode não ser inteiro. Mas o inteiro \hat{K} que satisfaaz a inequação e é o MLE, é o maior inteiro menor ou igual a $1/Z$.

① Prove que \hat{k} que satisfaça as inequações e é o MLE é o maior inteiro menor ou igual a $\frac{1}{2}z$

② Seja $p = \frac{1}{2}$, $n = 4$, e $X_1 = 0$, $X_2 = 20$, $X_3 = 1$, e $X_4 = 19$. Qual o valor de \hat{k} ?

③ O valor \hat{k} resolve a equação

$$(1-p)^{\hat{k}} = \prod_{i=1}^n (1-x_i z)$$

Onde $0 \leq z \leq (\max x_i)$. Seja $\hat{k}' = 0$ maior inteiro menor ou igual a $\frac{1}{2}z$, \hat{k} deve satisfazer

$$(k(1-p))^{\hat{k}} \geq \prod_{i=1}^n (k-x_i) \text{ e } ((k+1)(1-p))^{\hat{k}} \leq \prod_{i=1}^n (k+1-x_i).$$

Pois o lado direito da primeira equação é decrescente em \hat{k} , e porque $\hat{k} \leq \frac{1}{2}z$ (então $\hat{k} \leq \frac{1}{2}k'$) e $\hat{k}+1 > \frac{1}{2}z$, \hat{k} deve ser satisfazer as 2 inequações. Daí \hat{k} é o MLE.

④ Para $p = \frac{1}{2}$, temos que resolver

$$\left(\frac{1}{2}\right)^{\hat{k}} = (1-20z)(1-z)(1-19z)$$

que pode ser reduzida a resolver a equação cúbica $-380z^2 + 419z^3 - 40z + 15/16 = 0$. As raízes são 0.9998 , 0.0646 e 0.0381 , com respectivos \hat{k}' 's. 1, $\frac{1}{2}15$ e $\frac{1}{2}26$ para as 2 primeiras não menores que $\max x_i$. logo $\hat{k} = 26$.

(4) Seja X_1, \dots, X_n iid com uma de duas pdfs. Se $\theta = 0$, então

$$f(x|\theta) = \begin{cases} 1 & 0 < x \leq 1 \\ 0 & \text{c.c.} \end{cases}$$

caso $\theta = 1$, então

$$f(x|\theta) = \begin{cases} 1/(2\sqrt{x}) & 0 < x \leq 1 \\ 0 & \text{c.c.} \end{cases}$$

Encontre o MLE de θ .

$L(0|x) = 1, 0 < x_i \leq 1$, e $L(1|x) = \prod (2\sqrt{x_i})^{-1}, 0 < x_i \leq 1$.
Dai, MLE é one $1 \geq \prod (2\sqrt{x_i})^{-1}$ e isto é $1 \leq \prod (2\sqrt{x_i})^1$.

(5) Seja X_1, \dots, X_n iid com pdf

$$f(x|\theta) = \frac{1}{\theta}, \quad 0 < x \leq \theta, \quad \theta > 0$$

Estime θ usando ambos MM e MLE. Calcule a media e variancia dos estimadores. Qual você prefere?

Tirar de um mando $\text{Unif}(0, \theta)$. O método dos momentos é $\hat{\theta} = \bar{x}$, ou seja, $\hat{\theta} = \bar{x}/2$. Temos que

$$E\hat{\theta} = 2E\bar{x} = 2EX = \frac{2\theta}{2} = \theta$$

$$\text{Var}\hat{\theta} = 4\text{Var}\bar{x} = 4 \frac{\theta^2/12}{n} = \frac{\theta^2}{2n}.$$

A versão MM é

$$L(\theta|x) = \prod \frac{1}{\theta} \mathbb{I}(0 < x_i \leq \theta) = \frac{1}{\theta^n} \mathbb{I}(0 < x_{(n)} \leq \theta) \mathbb{I}(0 \leq x_{(1)} < \infty)$$

Onde $x_{(1)}$ e $x_{(n)}$ são respectivamente a menor e maior valor. Pela $\theta > x_{(n)}$, $L = \frac{1}{\theta^n}$, como é decrescente, L é maximizada por $\hat{\theta} = \max x_i$. $L = 0$ para $\theta < x_{(n)}$. Então o MLE é $\hat{\theta} = \max x_i$. A pdf de $\hat{\theta} = \max x_i$ é $n x^{n-1}/\theta^n$, $0 < x < \theta$. Daí

$$E\hat{\theta} = \frac{n}{n+1} \theta, \quad E\hat{\theta}^2 = \frac{n}{n+2} \theta^2 \quad \text{e} \quad \text{Var}\hat{\theta} = \frac{n\theta^2}{(n+2)(n+1)^2}$$

Com n grande ambos são quase unbiased e como $\text{Var}\hat{\theta} < \text{Var}\hat{\theta}$, $\hat{\theta}$ é preferível que $\hat{\theta}$.

⑥ Seja X_1, \dots, X_n iid com pdf

$$f(x|\theta) = \theta x^{\theta-1}, \quad 0 \leq x \leq 1, \quad 0 < \theta < \infty$$

a) Encontre o MLE de θ , e mostre que variação $\rightarrow 0$ quando $n \rightarrow \infty$.

b) Encontre o MM de θ .

a) $f(x|\theta) = \prod \theta x_i^{\theta-1} = \theta^n (\prod x_i)^{\theta-1} = L(\theta|x)$

$$\frac{\partial}{\partial \theta} \log L = \sum_{i=1}^n \left[n \log \theta + (\theta - 1) \sum \log x_i \right] = \frac{n}{\theta} + \sum \log x_i$$

igualando a zero temos $\hat{\theta} = \frac{n}{\sum \log x_i}$. A segunda deriva-

vada é $-n/\theta^2 < 0$, então temos o MLE. Para calcular a variação de $\hat{\theta}$, note que $Y_i = -\log X_i \sim \text{Exp}(\frac{1}{\theta})$, então $-\sum \log X_i \sim \text{gamma}(n, \frac{1}{\theta})$. Daí, $\theta = \frac{n}{\sum Y_i}$, onde $\text{Var gamma}(n, \frac{1}{\theta})$. Podemos calcular os primeiros e segundos momentos diretamente. Temos

$$E T^{-1} = \frac{\theta^n}{\Gamma(n)} \int_0^\infty \frac{1}{t} t^{n-1} e^{-\theta t} dt = \frac{\theta^n}{\Gamma(n)} \frac{\Gamma(n-1)}{\theta^{n-1}} = \frac{\theta}{n-1}$$

$$E T^{-2} = \frac{\theta^n}{\Gamma(n)} \int_0^\infty \frac{1}{t^2} t^{n-1} e^{-\theta t} dt = \frac{\theta^n}{\Gamma(n)} \frac{\Gamma(n-2)}{\theta^{n-2}} = \frac{\theta^2}{(n-1)(n-2)}$$

e portanto

$$\hat{E}\hat{\theta} = \frac{n}{n-1} \theta \text{ e } \text{Var}(\hat{\theta}) = \frac{n^2}{(n-1)^2(n-2)} \theta^2 \rightarrow 0$$

⑥ Portanto, como X é uma Beta ($\theta, 1$), $E(X) = \theta/(1+\theta)$ e o momento dos momentos é a solução de

$$\frac{1}{n} \sum X_i = \frac{\theta}{\theta+1} \Rightarrow \hat{\theta} = \frac{\sum X_i}{n - \sum X_i}$$

7) Seja X_1, \dots, X_n uma amostra para uma população com pdf exponencial

$$f(x|\theta) = \frac{1}{2} e^{1x-\theta}, -\infty < x < \infty, -\infty < \theta < \infty$$

Encontre o MLE de θ .

$$L(\theta|x) = \prod \frac{1}{2} e^{-|x_i-\theta|} = \frac{1}{2^n} e^{-\sum |x_i-\theta|}$$

Sendo $x_{(1)}, \dots, x_{(n)}$ estatística de ordem. Paus $x_{(j)} \leq \theta \leq x_{(j+1)}$,

$$\sum_{i=1}^n |x_{(i)} - \theta| = \sum_{i=1}^j (\theta - x_{(i)}) + \sum_{i=j+1}^n (x_{(i)} - \theta) = (2j-n)\theta - \sum_{i=1}^j x_{(i)} + \sum_{i=j+1}^n x_{(i)}$$

É uma função linear de θ que decresce para $j = n/2$ e
cresce para $j > n/2$. Se n é par, $2j-n=0$ se $j = n/2$. Então
a regressimilhança é constante entre $x_{(n/2)}$ e $x_{(n/2+1)}$, e algum
valor no intervalo é o MLE. Normalmente o ponto médio des-
se intervalo é dado como MLE. Se n é ímpar, a regressi-
milihança é minimizada com $\hat{\theta} = x_{(n+1)/2}$.

⑧ Seja X_1, \dots, X_n uma amostra de uma Gaussiana inversa

$$f(x|\mu, \lambda) = \left(\frac{\lambda}{2\pi x^3}\right)^{1/2} \exp\{-\lambda(x-\mu)^2/(2\mu^2 x)\}, x > 0.$$

a) Mostre que o MLE de μ e λ é

$$\hat{\mu}_n = \bar{X} \quad \text{e} \quad \hat{\lambda}_n = \frac{n}{\sum_i \frac{1}{x_i} - \frac{1}{\bar{X}}}$$

b) [Tweedie (1957)] mostre que $\hat{\mu}_n$ e $\hat{\lambda}_n$ são independentes, $\hat{\mu}_n$ tem distribuição inversa Gaussiana com parâmetros μ e $n\lambda$, e $n\lambda/\hat{\lambda}_n$ tem uma distribuição χ^2_{n-1} .

(i) Mostre que $\hat{\lambda}_2$ tem uma distribuição inversa Gaussiana com parâmetros μ e 2λ , $2\lambda/\hat{\lambda}_2$ tem uma distribuição χ^2_1 e elas são independentes.

(ii) Assuma o resultado é verdadeiro para $n=k$ e que temos um novo, observações independentes X . Estabeleça o passo para de indução passando $f(x, \hat{\mu}_k, \hat{\lambda}_k)$ para $f(x, \hat{\mu}_{k+1}, \hat{\lambda}_{k+1})$. Mostre que a densidade final é uma forma apropriada que o resultado da Tweedie segue.

a) A verossimilhança é

$$L(\mu, \lambda | x) = \frac{\lambda^{n/2}}{(2\pi)^n \prod x_i} \exp\left\{-\frac{\lambda}{2} \sum \frac{(x_i - \mu)^2}{\mu^2 x_i}\right\}$$

Para λ fixo, maximizar com respeito a μ é equivalente a minimizar a soma na expressão

$$\frac{\partial}{\partial \mu} \sum_{i=1}^n \frac{(x_i - \mu)^2}{\mu^2 x_i} = \sum_{i=1}^n \frac{2((x_i/\mu) - 1)}{x_i} \cdot \frac{x_i}{\mu^2}.$$

Igualando a zero $\sum_{i=1}^n \left(\frac{x_i}{\mu} - 1\right) = 0$, e resolvendo para μ temos $\hat{\mu} = \bar{x}$. Colocando $\hat{\mu}$ e maximizando em respeito a λ equivale a maximizar uma expressão da forma $\lambda^{n/2} e^{-\lambda b}$. O cálculo prático.

$$\hat{\lambda}_n = \frac{n}{2b} \text{ onde } b = \sum_{i=1}^n \frac{(x_i - \bar{x})^2}{x_i}$$

Finalmente,

$$\hat{b} = \sum_{i=1}^n \frac{x_i}{\bar{x}} - 2 \sum_{i=1}^n \frac{1}{\bar{x}} + \sum_{i=1}^n \frac{1}{x_i} = -\frac{n}{\bar{x}} + \sum_{i=1}^n \frac{1}{x_i} = \sum_{i=1}^n \left(\frac{1}{x_i} - \frac{1}{\bar{x}} \right)$$

a) i. ii. Fora do currículo de aula.

⑨ Suponha que X_1, X_2 são iid $\text{Exp}(\theta)$.

(a) Se observarmos apenas X_2 , mostre que o MLE é X_2 .

(b) Suponha que observarmos apenas $Z = (X_2 - 1)/X_2$. Encontre a distribuição conjunta de (X_1, Z) , e integre X_1 para conseguir a função de verossimilhança.

(c) Suponha $X_2 = 1$. Compare o MLE para θ nas partes (a) e (b).

(d) Se $\pi(\theta)$ é uma densidade a priori para θ , mostre que a distribuição a posteriori, com $X_2 = 1$, são diferentes nas partes ③ @ ④.

$$@ \quad L(\theta, X_2) = \frac{1}{\theta} e^{-X_2/\theta}$$

$$\log L(\theta, X_2) = -\log \theta - X_2/\theta$$

$$\frac{\partial}{\partial \theta} \ln L(\theta, X_2) = -\frac{1}{\theta} + \frac{X_2}{\theta^2} = 0 \Rightarrow \hat{\theta}_{MLE} = X_2.$$

(e) Sepa a transformação:

$$Z = (X_2 - 1)/X_1 \Rightarrow X_1 = W \\ W = X_1 \qquad \qquad X_2 = WZ + 1$$

O Jacobiano é $|J| = 1$, e

$$f_Z(z) = \int_{X_1} f_{X_1}(w) \int_{X_2} (WZ + 1) \cdot W dW = \frac{1}{\theta^2} e^{-\theta} \int_W w e^{-w(1+z)/\theta} dw$$

Como o intervalo de integração é $0 \leq w \leq 1/2$ se $z < 0$,
 $0 \leq w \leq \infty$ se $z \geq 0$. Então.

$$f_z(z) = \frac{1}{\theta^2} e^{-\theta z} \begin{cases} \int_0^{1/2} w e^{-w(1+z)/\theta} dw & z < 0 \\ \int_0^{\infty} w e^{-w(1+z)/\theta} dw & z \geq 0 \end{cases}$$

Usando o fato de que $\int w e^{-w/\theta} dw = -e^{-w/\theta} (aw + a^2)$, temos

$$f_z(z) = \frac{-1}{\theta^2} \begin{cases} \int_{20}^{1/(1+z)} e^{-(1+z)/\theta} (1+w-20) dw & z < 0 \\ \frac{1}{(1+z)^2} & z \geq 0 \end{cases}$$

③ Da parte ② temos $\hat{\theta} = 1$. Para parte ④ $X_2 = 1 \rightarrow z = 0$,
dai, $\hat{\theta} = \infty$.

④ A parteijar é a verossimilhança normalizada, vezes
a priori, entre pelas suas formas em ② e ④ de fato das
só diferentes.

⑩ Suponha que as v.a. y_1, \dots, y_n satisfazem

$$y_i = \beta x_i + \epsilon_i$$

onde x_1, \dots, x_n são constantes fixas, e $\epsilon_1, \dots, \epsilon_n$ iid $N(0, \sigma^2)$, σ^2 é desconhecida.

a) Encontre uma estatística suficiente com 2 dimensões para (β, σ^2) .

b) Encontre o MLE de β , e mostre que é um estimador não viésado de β .

c) Encontre a distribuição de MLE de β .

$$\begin{aligned} @ L(\theta | y) &= \prod_i \frac{1}{\sqrt{2\pi\sigma^2}} \exp \left\{ -\frac{1}{2\sigma^2} (y_i - \beta x_i)^2 \right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum (y_i^2 - 2\beta x_i y_i + \beta^2 x_i^2) \right\} \\ &= (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{\beta^2 \sum x_i^2}{2\sigma^2} \right\} \exp \left\{ -\frac{1}{2\sigma^2} \sum y_i^2 + \frac{\beta}{\sigma^2} \sum x_i y_i \right\} \end{aligned}$$

Então $(\sum y_i^2, \sum x_i y_i)$ é estatística suficiente para (β, σ^2) .

$$\text{b) } \log L(\beta, \sigma^2 | y) = -\frac{n}{2} \log(2\pi) - \frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum y_i^2 + \frac{\beta}{\sigma^2} \sum x_i y_i - \frac{\beta^2}{2\sigma^2} \sum x_i^2$$

Para um valor fixo de σ^2 ,

$$\frac{\partial}{\partial \beta} \log L = \frac{1}{\sigma^2} \sum x_i y_i - \frac{\beta}{\sigma^2} \sum x_i^2 = 0 \Rightarrow \beta = \frac{\sum x_i y_i}{\sum x_i^2}.$$

Também,

$$\frac{\partial^2 \log L}{\partial \beta^2} = \frac{1}{n} \sum x_i^2 < 0,$$

então $\hat{\beta}$ é ótimo. Porque $\hat{\beta}$ não depende de σ^2 , a.o.
M.F. $E[\hat{\beta}]$ é ótima.

$$E[\hat{\beta}] = \frac{\sum x_i E[Y_i]}{\sum x_i^2} + \frac{\sum x_i \beta X_i}{\sum x_i^2} = \beta.$$

③ $\hat{\beta} = \sum \alpha_i x_i$ onde $\alpha_i = x_i / \sum x_i^2$ são constantes. Só $\hat{\beta}$ é
normalmente distribuído com média β , e

$$\text{Var}[\hat{\beta}] = \sum \alpha_i^2 \text{Var}[Y_i] = \sum \left(\frac{x_i}{\sum x_i^2} \right)^2 \sigma^2 = \frac{\sum x_i^2}{(\sum x_i^2)^2} \sigma^2 = \frac{\sigma^2}{\sum x_i^2}$$

(11) Seja y_1, \dots, y_n definidas no exercício anterior

a) Mostre que $\left[\sum (y_i x_i) \right] / n$ é também não viésado de β .

b) Calcule a exata variação de $\left[\sum (y_i x_i) \right] / n$, e compare.

$$\text{a) } E \frac{1}{n} \sum \frac{y_i}{x_i} = \frac{1}{n} \sum \frac{E y_i}{x_i} = \frac{1}{n} \sum \frac{\beta x_i}{x_i} = \beta.$$

$$\text{b) } \text{Var} \frac{1}{n} \sum \frac{y_i}{x_i} = \frac{1}{n^2} \sum \frac{\text{Var} y_i}{x_i^2} = \frac{\sigma^2}{n^2} \sum \frac{1}{x_i^2}.$$

(12) Se S^2 é uma amostra de variancia baseada na amostra de tamanho n para uma distribuição normal, sabemos que $(n-1)S^2/\sigma^2$ tem distribuição χ^2_{n-1} . A prior conjugada para σ^2 é uma gamma-inversa (α, β), dada por

$$\pi(\sigma^2) = \frac{1}{\Gamma(\alpha)\beta^{\alpha}} \frac{1}{(\sigma^2)^{\alpha+1}} e^{-\frac{1}{\beta\sigma^2}}, \quad \alpha, \beta > 0,$$

onde α e β são constantes positivas. Mostre que a distribuição posterior de σ^2 é gamma-inversa ($\alpha + \frac{n+1}{2}, [\frac{(n-1)S^2}{2} + \frac{1}{\beta}]^{-1}$). Encontre a média da desta distribuição e a estimadora de Bayes de σ^2 .

Seja $t = n^2$ e $\theta = \sigma^2$. Como $(n-1)S^2/\sigma^2 \sim \chi^2_{n-1}$, temos

$$f(t|\theta) = \frac{1}{\Gamma((n-1)/2)} \frac{1}{2^{(n-1)/2}} \left(\frac{n-1}{\theta} t\right)^{\frac{n-1}{2}-1} e^{-\frac{(n-1)t}{2\theta}} \cdot \frac{n-1}{\theta}.$$

Com $\pi(\theta)$ dada, temos (ignorando termos que não dependem de θ):

$$\pi(\theta|t) \propto \left[\left(\frac{1}{\theta}\right)^{\frac{n-1}{2}-1} e^{-\frac{(n-1)t}{2\theta}} \right] \left[\frac{1}{\theta} \right]^{\frac{n-1}{2}} e^{-\frac{1}{\beta\theta}}$$

$$\propto \left(\frac{1}{\theta}\right)^{\frac{n-1}{2}+\alpha+1} \exp\left\{-\frac{1}{\theta} \left[\frac{(n-1)t}{2} + \frac{1}{\beta}\right]\right\}.$$

reconhecemos como um kernel de uma gamma-inversa, com

$$\alpha = \frac{n-1}{2} + \alpha \quad \text{e} \quad \beta = \left[\frac{(n-1)t}{2} + \frac{1}{\beta}\right]^{-1}$$

Calculando diretamente a média de soma gamma menor como $1 / ((\alpha - 1)^{\frac{1}{\beta}})$, então

$$E[\theta | t] = \frac{\frac{n-1}{2}t + \frac{1}{\beta}}{\frac{n-1}{2} + \alpha - 1} = \frac{\frac{n-1}{2}\gamma + \frac{1}{\beta}}{\frac{n-1}{2} + \alpha - 1}$$

Que é o estimador de Bayes.

(13) Supõe que observamos X_1, \dots, X_n onde

$X_i|\theta_i \sim N(\theta_i, \sigma^2)$, $i=1, \dots, n$ independentes

$\theta_i \sim N(\mu, \tau^2)$, $i=1, \dots, n$ independente

a) Mostre que a distribuição marginal de X_i é $N(\mu, \sigma^2 + \tau^2)$ e que marginalmente X_1, \dots, X_n são iid.

b) Mostre, em geral, que se

$X_i|\theta_i \sim f(x|\theta_i)$, $i=1, \dots, n$ independentes

$\theta_i \sim \pi(\theta|y)$, $i=1, \dots, n$ independentes

então a marginalização, X_1, \dots, X_n é iid.

a) Vamos usar o item b), então X_i são independentes e cada uma tem marginal

$$\begin{aligned} m(x|\mu, \sigma^2, \tau^2) &= \int_{-\infty}^{\infty} f(x|\theta, \sigma^2) \pi(\theta|\mu, \tau^2) d\theta \\ &= \int_{-\infty}^{\infty} \frac{1}{2\pi\sigma\sqrt{2}} e^{-(x-\theta)^2/2\sigma^2} e^{-(\theta-\mu)^2/2\tau^2} d\theta. \end{aligned}$$

Completando quadrado em θ e escrevendo a soma dos dois exponentes como

$$\frac{\left(\theta - \frac{x\tau^2}{\sigma^2 + \tau^2} + \frac{\mu\sigma^2}{\sigma^2 + \tau^2}\right)^2}{2\sigma^2\tau^2} - \frac{(x-\tau)^2}{2(\sigma^2 + \tau^2)}$$

Apenas o primeiro termo tem θ , chamando $-A(\theta)$. Também é o núcleo de uma normal. Daí,

$$\int_{-\infty}^{\infty} e^{-A(\theta)} d\theta = \frac{1}{\sqrt{2\pi}} \frac{1}{\sigma r} \frac{1}{\sqrt{\theta^2 + r^2}}$$

e a pdf marginal é

$$m(x|\mu, \sigma^2, r^2) = \frac{1}{2\pi\sigma r} \frac{1}{\sqrt{2\pi}} \frac{1}{\sigma r} \frac{\exp\left\{-\frac{(x-\mu)^2}{2(\sigma^2+r^2)}\right\}}{\sqrt{\sigma^2+r^2}}$$

$$= \frac{1}{\sqrt{2\pi}\sqrt{\sigma^2+r^2}} \exp\left\{-\frac{(x-\mu)^2}{2(\sigma^2+r^2)}\right\}$$

uma $N(\mu, \sigma^2 + r^2)$.

(b) Para uma observação X e θ a pdf conjunta é

$$l(x, \theta | \gamma) = \prod l(x_i, \theta; \gamma), f(x | \theta) \pi(\theta | \gamma).$$

e a pdf marginal de X é

$$m(x | \gamma) = \int_{-\infty}^{\infty} l(x, \theta | \gamma) d\theta.$$

Daí, a pdf conjunta de $X = (X_1, \dots, X_n)$ e $\theta = (\theta_1, \dots, \theta_m)$ é

$$l(x, \theta | \gamma) = \prod l(x_i, \theta_i; \gamma),$$

e a marginal de X é

$$m(x|T) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} \prod_{i=1}^n h(x_i; \theta_i; T) d\theta_1 \dots d\theta_n$$

$$= \int_{-\infty}^{\infty} \dots \left\{ \int_{-\infty}^{\infty} h(x_i; \theta_i; T) d\theta_i \right\}_{i=1}^n \prod_{i=1}^n h(x_i; \theta_i; T) d\theta_i$$

A integral de $d\theta_i$ é apenas $m(x_i|T)$ e não é uma função de $\theta_2, \dots, \theta_n$. Então, $m(x|T)$ pode ser calculada para das integrais. Fazendo isso com cada integral

$$m(x|T) = \prod m(x_i|T)$$

Como esta marginal é um produto de pdf's X_1, X_n não independentes e elas tem cada uma a mesma distribuição marginal, $m(x_i|T)$.