

## Liste 2.5

① Seja  $X_1, \dots, X_n$  iid com pdf

$$f(x|\theta) = \theta x^{\theta-1}, \quad 0 < x \leq 1, \quad 0 < \theta < \infty.$$

② Encontre o MLE de  $\theta$ , e mostre que a variancia  $\rightarrow 0$  quando  $n \rightarrow \infty$ .

③ Encontre o estimador de metade dos momentos para  $\theta$

$$f(x|\theta) = \prod \theta x_i^{\theta-1} = \theta^n (\prod x_i)^{\theta-1} = L(\theta|x)$$

$$\Rightarrow \frac{\partial}{\partial \theta} \log L = \frac{\partial}{\partial \theta} \left[ n \log \theta + (\theta-1) \sum \log x_i \right] = \frac{n}{\theta} + \sum \log x_i$$

$$\Rightarrow \frac{\partial}{\partial \theta} \log L = \frac{n}{\theta} + \sum \log x_i = 0 \Rightarrow \theta = \frac{n}{\sum \ln x_i}$$

E a segunda derivada é  $-\frac{n}{\theta^2} < 0$ , então este é o MLE. Para calcular a variancia de  $\hat{\theta}$ , note que,  $Y_i = -\log x_i \sim \text{Exp}(1/\theta)$ , então  $-\sum \log x_i \sim \text{Gamma}(n, 1/\theta)$ . Seja  $\hat{\theta} = \bar{T} = \frac{n}{T}$ , onde  $T \sim \text{Gamma}(n, 1/\theta)$ .

Temos

$$E \frac{1}{T} = \frac{\theta^n}{\Gamma(n)} \int_0^\infty \frac{1}{t} t^{n-1} e^{-\theta t} dt = \frac{\theta^n}{\Gamma(n)} \frac{\Gamma(n-1)}{\theta^{n-1}} = \frac{\theta}{n-1}$$

$$E \frac{1}{T^2} = \frac{\theta^n}{\Gamma(n)} \int_0^\infty \frac{1}{t^2} t^{n-1} e^{-\theta t} dt = \frac{\theta^n}{\Gamma(n)} \frac{\Gamma(n-2)}{\theta^{n-2}} = \frac{\theta^2}{(n-1)(n-2)}$$

$$\text{e daí } E \hat{\theta} = \frac{n}{n-1} \theta \text{ e } \text{Var.} \hat{\theta} = \frac{n^2}{(n-1)^2 (n-2)} \theta^2 \rightarrow 0 \quad (n \rightarrow \infty)$$

(6)

$$EX_i = \int_0^1 x \theta x^{\theta-1} dx$$

$$= \theta \int_0^1 x^\theta dx = \theta \left[ \frac{x^{\theta+1}}{\theta+1} \right]_0^1 = \frac{\theta}{\theta+1}$$

Dáu  $\frac{1}{n} \sum X_i = \hat{\theta} \Rightarrow \hat{\theta} = \frac{\sum X_i}{n - \sum X_i}$

2) Seja  $X_1, \dots, X_n$  uma amostra aleatória com pmf

$$P_\theta(X=x) = \theta^x (1-\theta)^{1-x}, \quad x=0 \text{ ou } 1, \quad 0 \leq \theta \leq \frac{1}{2}.$$

a) Encontre o estimador de método de momentos e MLE de  $\theta$ .

b) Encontre o MSE de cada estimador.

c) Qual você prefere? Justifique.

a) MM:

$$EX = \theta = \frac{1}{n} \sum X_i = \bar{X} \Rightarrow \hat{\theta} = \bar{X}.$$

$$\text{MLE:} \quad f(x|\theta) = \prod_{i=1}^n \theta^{x_i} (1-\theta)^{1-x_i} = L(\theta|x)$$

$$\Rightarrow \frac{\partial}{\partial \theta} (\ln L(\theta|x)) = \frac{\partial}{\partial \theta} \left( \sum x_i \ln \theta + \sum (1-x_i) \ln (1-\theta) \right)$$

$$= \frac{\partial}{\partial \theta} \left( \ln \theta \sum x_i + \ln (1-\theta) n - \ln (1-\theta) \sum x_i \right)$$

$$= \frac{\sum x_i}{\theta} - \frac{n}{1-\theta} + \frac{\sum x_i}{1-\theta} = 0$$

$$\Rightarrow (1-\theta) \sum x_i - n\theta + \theta \sum x_i = 0 = \sum x_i - n\theta = 0$$

$$\Rightarrow \hat{\theta} = \frac{\sum x_i}{n}$$

quando  $\bar{X} \leq \frac{1}{2}$ , pois  $L(\theta|x)$  está considerando o intervalo de  $\theta$ , logo  $\theta = \min\{\bar{X}, \frac{1}{2}\}$

$$\textcircled{1} \quad \text{O MSE de } \hat{\theta} = \text{Var}(\hat{\theta}) + \text{bias}(\hat{\theta})^2 = \left( \frac{(1-\theta)\theta}{n} \right) + \theta^2.$$

O MSE de  $\hat{\theta}$ :

$$\text{MSE}(\hat{\theta}) = E(\hat{\theta} - \theta)^2 = \sum_{y=0}^n (\hat{\theta} - \theta)^2 \binom{n}{y} \theta^y (1-\theta)^{n-y}$$

$$= \sum_{y=0}^{\lfloor n/2 \rfloor} \left( \frac{Y}{n} - \theta \right)^2 \binom{n}{y} \theta^y (1-\theta)^{n-y}$$

$$+ \sum_{y=\lfloor n/2 \rfloor + 1}^n \left( \frac{1}{2} - \theta \right)^2 \binom{n}{y} \theta^y (1-\theta)^{n-y},$$

Onde  $Y = \sum X_i$  é binomial ( $n, \theta$ ).

\textcircled{2} Considerando o MSE, temos que

$$\text{MSE}(\hat{\theta}) = E(\hat{\theta} - \theta)^2 = \sum_{y=0}^n \left( \frac{Y}{n} - \theta \right)^2 \binom{n}{y} \theta^y (1-\theta)^{n-y}$$

$$\text{Portanto, } \text{MSE}(\hat{\theta}) - \text{MSE}(\bar{\theta}) = \sum_{y=\lfloor n/2 \rfloor + 1}^n \left[ \left( \frac{Y}{n} - \theta \right)^2 - \left( \frac{1}{2} - \theta \right)^2 \right] \binom{n}{y} \theta^y (1-\theta)^{n-y}$$

$$= \sum_{y=\lfloor n/2 \rfloor + 1}^n \left( \frac{Y}{n} + \frac{1}{2} - 2\theta \right) \left( \frac{Y}{n} - \frac{1}{2} \right) \binom{n}{y} \theta^y (1-\theta)^{n-y}$$

Se  $\frac{Y}{n} > \frac{1}{2}$  e  $\theta \leq \frac{1}{2}$  então os termos são positivos.

Daí,  $\text{MSE}(\hat{\theta}) < \text{MSE}(\bar{\theta})$  V  $0 < \theta < \frac{1}{2}$ .

③ Suponha que variáveis aleatórias  $y_1, y_n$  estejam

$$y_i = \beta x_i + \epsilon_i$$

onde  $x_1, x_n$  não são constantes fixas, e  $\epsilon_i \sim N(0, \sigma^2)$ ,  $\sigma^2$  desconhecido.

a) Encontre uma estatística bi-dimensional suficiente para  $(\beta, \sigma^2)$ .

b) Encontre o MLE de  $\beta$ , e mostre que é não viésado.

c) Encontre a distribuição do MLE de  $\beta$ .

$$\begin{aligned} \text{(a)} \quad L(\theta | Y) &= \prod_{i=1}^n \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left\{-\frac{1}{2\sigma^2}(y_i - \beta x_i)^2\right\} \\ &= (2\pi\sigma^2)^{\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum (y_i^2 - 2\beta x_i y_i + \beta^2 x_i^2)\right\} \\ &= (2\pi\sigma^2)^{\frac{n}{2}} \exp\left\{\frac{\beta^2 \sum x_i^2}{2\sigma^2}\right\} \exp\left\{-\frac{1}{2\sigma^2} \sum y_i^2 + \frac{\beta \sum x_i y_i}{\sigma^2}\right\} \end{aligned}$$

$T(x_1, \dots, x_n) = (\sum y_i^2, \sum x_i y_i)$  é suficiente.

$$\text{(b)} \quad \ln L(\beta, \sigma^2 | Y) = -\frac{n}{2} \ln(2\pi) - \frac{n}{2} \ln \sigma^2 - \frac{1}{2\sigma^2} \sum y_i^2 + \frac{\beta \sum x_i y_i - \beta^2 \sum x_i^2}{2\sigma^2}$$

Fixando  $\sigma^2$ ,

$$\frac{\partial}{\partial \beta} \ln L = \frac{1}{\sigma^2} \sum x_i y_i - \frac{\beta}{\sigma^2} \sum x_i^2 = 0 \Rightarrow \hat{\beta} = \frac{\sum x_i y_i}{\sum x_i^2}$$

Também,

$$\frac{\partial^2 \text{AL}}{\partial \beta^2} = \frac{1}{\sigma^2} \sum x_i^2 < 0$$

então é maximo. Como  $\hat{\beta}$  não depende de  $\sigma^2$ , é o MLE. E  $\hat{\beta}$  é não viésado

$$\hat{\beta} = \frac{\sum x_i E_{\beta} Y_i}{\sum x_i^2} = \frac{\sum x_i \beta x_i}{\sum x_i^2} = \beta.$$

c)  $\hat{\beta} = \sum a_i Y_i$ , onde  $a_i = x_i / \sum x_j^2$  constante. Pelo resultado [6.10] [CB],  $\hat{\beta}$  é uma normal com média  $\beta$ , e

$$\text{Var}(\hat{\beta}) = \sum a_i^2 \text{Var}(Y_i) = \sum \left( \frac{x_i}{\sum x_j^2} \right)^2 \sigma^2 = \frac{\sum x_i^2}{(\sum x_j^2)^2} \sigma^2 = \frac{\sigma^2}{\sum x_j^2}$$

④ Considere  $Y_1, \dots, Y_n$  como no exercício ③

a) Mostre que  $\sum Y_i / \sum X_i$  é um estimador não viésado para  $\beta$ .

b) Calcule a variancia de  $\sum Y_i / \sum X_i$  e compare com a variancia do MLE.

c) Não é viésado por

$$E_{\beta} \left[ \frac{\sum Y_i}{\sum X_i} \right] = \frac{\sum X_i E_{\beta} \beta - \beta}{\sum X_i}$$

a) E para a variancia

$$\text{Var} \left( \frac{\sum Y_i}{\sum X_i} \right) = \frac{1}{(\sum X_i)^2} \sum \text{Var} Y_i = \frac{\sum \sigma^2}{n^2 \bar{x}^2} = \frac{\sigma^2}{n \bar{x}^2}$$

Como  $\sum X_i^2 - n\bar{x}^2 = \sum (x_i - \bar{x})^2 \geq 0$ ,  $\sum X_i^2 \geq n\bar{x}^2$ . Daí

$$\text{Var} \hat{\beta} = \frac{\sigma^2}{\sum X_i^2} < \frac{\sigma^2}{n \bar{x}^2} = \text{Var} \left( \frac{\sum Y_i}{\sum X_i} \right)$$

5) Considere  $y_1, \dots, y_n$  como no exercício 3)

a) Mostre que  $\left[ \sum (y_i/x_i) \right]/n$  é não viésado  $\beta$

b) Calcule a variancia do estimador e compare com os exercícios 3 e 7.

a)  $\frac{1}{n} E \sum \frac{y_i}{x_i} = \frac{1}{n} \sum \frac{EY_i}{x_i} = \frac{1}{n} \sum \frac{\beta x_i}{x_i} = \beta$

b)  $\frac{1}{n^2} \text{Var} \sum \frac{y_i}{x_i} = \frac{1}{n} \sum \frac{\text{Var} Y_i}{x_i^2} = \frac{\sigma^2}{n^2} \sum \frac{1}{x_i^2}$

Temos que,  $\frac{1}{n} \sum \frac{1}{x_i^2} \geq \frac{n}{\sum x_i^2}$ . Daí

$$\text{Var} \hat{\beta} = \frac{\sigma^2}{\sum x_i^2} \leq \frac{\sigma^2}{n^2} \sum \frac{1}{x_i^2} = \text{Var} \frac{1}{n} \sum \frac{y_i}{x_i}$$

E usando a desigualdade de Jensen, temos que

$$\frac{1}{\bar{x}^2} \leq \frac{1}{n} \sum \frac{1}{x_i^2}$$

Daí,

$$\text{Var} \left( \frac{\sum y_i}{\sum x_i} \right) = \frac{\sigma^2}{n \bar{x}^2} \leq \frac{\sigma^2}{n^2} \sum \frac{1}{x_i^2} = \text{Var} \frac{1}{n} \sum \frac{y_i}{x_i}$$

6 Seja  $X_1, \dots, X_n$  iid Bernoulli( $p$ ). Mostre que a variancia de  $\bar{X}$  satisfaz o Limite Inferior de Cramér-Rao e por isso  $\bar{X}$  é o melhor estimador não-viésado de  $p$ .

Assunto não coberto.

⑦ Seja  $X_1, \dots, X_n$  uma amostra aleatória de uma população com média  $\mu$  e variância  $\sigma^2$ .

a) Mostre que o estimador  $\sum a_i X_i$  é não viésado para  $\mu$  se  $\sum a_i = 1$ .

b) Sobre todos os estimadores da forma  $\sum a_i X_i$  encontre o com variância mínima e calcule ela.

a)  $E_u \sum a_i X_i = \sum E a_i X_i = \sum a_i \mu = \mu \cdot 1 = \mu$

b)  $\text{Var} \sum a_i X_i \stackrel{iid}{=} \sum \text{Var} a_i X_i = \sum a_i^2 \text{Var} X_i = \sigma^2 \sum a_i^2$

Então, queremos minimizar  $\sum a_i^2$  com restrição  $\sum a_i = 1$ .  
Somando e subtraindo a média,  $\frac{1}{n}$ , temos

$$\sum a_i^2 = \sum_i \left[ (a_i - \frac{1}{n}) + \frac{1}{n} \right]^2 = \sum (a_i - \frac{1}{n})^2 + \frac{1}{n}.$$

Aqui,  $\sum a_i^2$  é minimizada com  $a_i = \frac{1}{n}$ ,  $\forall i$ . Então  $\sum X_i = \bar{X}$  tem variância mínima, com variância de  $\frac{\sigma^2}{n}$ .

8) Prove o que foi dito no exemplo 7.3.24 [CB]: Seja  $T$  uma estatística suficiente completa para o parâmetro  $\theta$ , e  $l(x_1, \dots, x_n)$  é algum estimador não viésado de  $T(\theta)$ , então  $\phi(T) = E[l(x_1, \dots, x_n)|T]$  é o melhor estimador não viésado de  $T(\theta)$ .

(Teorema de Rao-Blackwell)

$$T(\theta) = E_\theta l = E_\theta [l|T] = E_\theta \phi(T)$$

Logo  $\phi(T)$  é não viésado para  $T(\theta)$ . Também

$$\text{Var}_\theta l = \text{Var}_\theta [E(l|T)] + E_\theta [\text{Var}(l|T)]$$

$$= \text{Var}_\theta \phi(T) + E_\theta [\text{Var}(l|T)]$$

$$\geq \text{Var}_\theta (T)$$

Logo,  $\phi(T)$  é o melhor estimador não viésado de  $T(\theta)$ .

9 Seja  $X_1, \dots, X_n$ , <sup>iid</sup> Bernoulli( $p$ ), e defina a função  $h(p)$  por

$$h(p) = P\left(\sum_{i=1}^n X_i > X_{n+1} \mid p\right)$$

a probabilidade de das primeiras  $n$  observações excederem  $(n+1)^{\text{a}}$  observação.

a) Mostre que

$$T(X_1, \dots, X_n) = \begin{cases} 1 & \text{se } \sum_{i=1}^n X_i > X_{n+1} \\ 0 & \text{c.c.} \end{cases}$$

é um estimador não viésado de  $h(p)$ .

b) Encontre o melhor estimador não viésado de  $h(p)$ .

c) Té uma V.a. Bernoulli. Diz

$$E_p T = P_p(T=1) = P_p\left(\sum_{i=1}^n X_i > X_{n+1} \mid p\right) = h(p)$$

d)  $\sum_{i=1}^{n+1} X_i$  é uma estatística suficiente completa para  $\theta$ , então  $E[T \mid \sum_{i=1}^{n+1} X_i]$  é o melhor estimador não viésado de  $h(p)$ . Temos

$$E[T \mid \sum_{i=1}^{n+1} X_i = y] = P\left(\sum_{i=1}^n X_i > X_{n+1} \mid \sum_{i=1}^{n+1} X_i = y\right)$$

$$= P\left(\sum_{i=1}^n X_i > X_{n+1}, \sum_{i=1}^{n+1} X_i = y\right) / P\left(\sum_{i=1}^{n+1} X_i = y\right)$$

O denominador é igual a  $\binom{n+1}{y} p^y (1-p)^{n+1-y}$ . Se  $y=0$  o numerador é

$$P\left(\sum_{i=1}^n X_i > X_{n+1}, \sum_{i=1}^{n+1} X_i = 0\right) = 0$$

Se  $y > 0$  o numerador é

$$P\left(\sum_{i=1}^n X_i > 0, \sum_{i=1}^n X_i = y\right) P(X_{n+1} = 0) + P\left(\sum_{i=1}^n X_i > 1, \sum_{i=1}^n X_i = y-1\right) P(X_{n+1} = 1)$$

Para todo  $y > 0$ ,

$$P\left(\sum_{i=1}^n X_i > 0, \sum_{i=1}^n X_i = y\right) = P\left(\sum_{i=1}^n X_i = y\right) = \binom{n}{y} p^y (1-p)^{n-y}$$

Se  $y = 1$  ou  $2$ , então

$$P\left(\sum_{i=1}^n X_i > 1, \sum_{i=1}^n X_i = y-1\right) = 0$$

E se  $y > 1$ , então

$$P\left(\sum_{i=1}^n X_i > 1, \sum_{i=1}^n X_i = y-1\right) = P\left(\sum_{i=1}^n X_i = y-1\right) = \binom{n}{y-1} p^{y-1} (1-p)^{n-y+1}$$

Portanto, o OMVUE é

$$E\left(T \mid \sum_{i=1}^n X_i = y\right) = \begin{cases} 0, & , y = 0 \\ \frac{1}{(n+1)(n+1-y)} \rightarrow , y = 1 \text{ ou } 2 \\ 1, & , y > 2 \end{cases}$$